

Tohoku folktale corpus / 東北地方民話コーパス

This corpus (database) is a digitized and annotated collection of Tohoku region folktales stored on open-reel and analog tapes. These folktales were collected by the folktale collector Tokuo Sasaki (1929-2010), who began collecting them in 1957, mainly in the Tohoku region.

本コーパス(データベース)は, オープンリールテープやアナログテープに保存されていた東北地方民話(昔話)をデジタル化し, アノテーションを付与したものです. この昔話は, 昔話採集家の佐々木徳夫(1929-2010)が1957年より東北地方を中心に収集したものです.

Introduction / はじめに

In this corpus, some words that would not be considered appropriate today may be used, but we have left them as they are, considering the unique circumstances of folktales that were passed down within the society of the common people of that time.

本コーパス内において, 現代では適当とみなされない言葉が使用されている場合がありますが, 当時の庶民社会の内部で語り継がれてきた昔話特有の事情を鑑み, そのまま残しました.

Description / 内容

- speech/ ... speech data / 音声ファイル
 - {tape}/ ... tape ID / テープ番号
- transcript/ ... transcription / 書き起こしファイル
 - shift-jis/ ... for Windows / Windows 用
 - utf-8/
 - {tape}/
- meta_info/ ... meta info / メタ情報
 - shift-jis/
 - utf-8/
 - {tape}/
- paper.pdf ... paper / 論文
- README.md
- README.pdf

Speech data is sampled at 16kHz, formatted as RIFF WAV. Speaker names are pseudonymized and start with F(emale) or M(ale).

音声ファイルは, 16kHzサンプリング, RIFF WAV 形式で保存されています. 話者名は仮名化されており, 女性ならF, 男性ならMから始まります.

Terms of use / 使い方

This corpus may be used for use (including commercial and non-commercial uses) of information analysis of spoken language except in the following cases:

- Any use that violates public order and standards of decency

- Any use that includes contents intended to defame or discredit the speaker or others

本コーパスは, 以下の場合を除き, 音声言語の情報解析の用途(商用, 非商用を問わない)で利用可能です.

- 公序良俗に反する利用
- 話者, または他者を誹謗中傷したり, 信用失墜を意図する内容を含む利用

Contributors / 作成者

- **Shinnosuke Takamichi / 高道 慎之介**
 - **main contributor / 責任者**
 - The University of Tokyo / 東京大学
 - <https://sites.google.com/site/shinnosuketakamichi/home>
 - shinnosuke_takamichi@ipc.i.u-tokyo.ac.jp
- Naoko Tanji / 丹治 尚子
 - The University of Tokyo / 東京大学
 - <https://www.sp.ipc.i.u-tokyo.ac.jp/>
- Ai Morimatsu / 森松 亜依
 - The University of Tokyo / 東京大学
- Takaaki Saeki / 佐伯 高明
 - The University of Tokyo / 東京大学
 - <https://takaaki-saeki.github.io/>
- Hiroshi Saruwatari / 猿渡 洋
 - The University of Tokyo / 東京大学
 - <https://researchmap.jp/read0102891/>
- Junko Shoji / 庄司潤子
 - Sendai Literature Museum / 仙台文学館
 - <https://www.sendai-lit.jp/>
- Shoichi Satoh / 佐藤照一
 - Sendai Literature Museum / 仙台文学館
 - <https://www.sendai-lit.jp/>

Paper / 論文

- 高道 慎之介, 丹治 尚子, 佐伯 高明, 森松 亜依, 庄司 潤子, 佐藤 照一, 猿渡 洋, "東北方言昔話に関する歴史的音声コーパスと機械学習ベース自動音声復元の試み," *じんもんこん* 2022, Dec. 2022.

Project page / プロジェクトページ

- https://sites.google.com/site/shinnosuketakamichi/research-topics/tohoku-dialect_corpus?authuser=0

Update / 更新情報

- 2022/12/08 ver. 0.1 ... 2 speaker / 2話者
- YYYY/MM/DD